Diagnóstico y necesidades: Aguas Andinas, continuidad y eficiencia operacional

E1 · Grupo Aguas Andinas: Byron, Bastian, Sepu, Jose · Visualización de Datos 2026 S2 · Prof. Viktor Tapia

Datos y metas 100% simulados con fines docentes; no representan instalaciones ni resultados reales de la empresa. Fechas en UTC.

1. Audiencias, decisión y preguntas

- **Audiencia ejecutiva:** jefatura ficticia de operaciones y planificación, que decide cómo asignar tres inspecciones y recursos; necesita prioridades comparables, cobertura e incertidumbre.
- **Audiencia operacional:** equipo ficticio de terreno, telemetría y mantenimiento, que define qué revisar y qué evidencia levantar; necesita detalle por sector y semana.
- **Decisión:** priorizar tres sectores para inspección.

#	Pregunta medible	Indicador / cálculo	Período · población	Acción que cambia según la respuesta
1	¿Qué sectores podrían quedar bajo la meta docente de continuidad considerando las horas desconocidas?	Continuidad ponderada por conexiones, observada y con límites 0/60 min; comparar con 99,5%.	Ene–dic 2025 · sector-horas por sector	Priorizar sectores cuyo límite superior queda bajo la meta; recopilar evidencia si el intervalo cruza la meta.
2	¿Dónde es mayor la diferencia entre volumen de entrada y salida?	Σ(entrada − salida) / Σ entrada, en m³ tras convertir L; con volumen válido y denominador positivo.	Ene–dic 2025 · lecturas con ambos volúmenes convertibles	Revisar balance y medición, sin inferir causa solo por asociación.
3	¿Qué tres sectores combinan señales operacionales y medición confiable para inspección?	Ranking de continuidad, diferencia, kWh/m³, costo CLP/m³ y calidad; con y sin filtro de cobertura mínima.	Ago–dic 2025 · 30 sectores	Asignar tres inspecciones y definir evidencia sobre operación y sensores según cambie el ranking.

Fuera de alcance: potabilidad, cumplimiento regulatorio, causalidad, predicción.

2. Inventario de la fuente

Tabla	Rol	Filas	Clave	Granularidad	Período / corte
`base/telemetria_horaria.csv`	Hecho	130.972	`medicion_id`	Sector-hora	Ene–jun 2025 · corte 2025-07-08
`actualizacion/telemetria_horaria.csv`	Hecho	22.432	`medicion_id`	Sector-hora	Jul 2025 · corte 2025-08-08
`ampliacion/telemetria_horaria.csv`	Hecho	100.000	`medicion_id`	Sector-hora	Ago–dic 2025 · corte 2026-01-08
`dimensiones/sectores.csv`	Dimensión fuente	30	`sector_id`	Una fila por sector	Catálogo original
`dimensiones/metas_ancho.csv`	Dimensión fuente	30	`sector_id + indicador`	Meses en columnas	Ene–jul; reemplazada
`complementarios/sectores_historial.csv`	Dimensión con vigencia	60	`sector_id + vigente_desde`	Sector y versión	Corte de versión 2025-10-01
`complementarios/tarifas_energia.csv`	Complementaria	150	`sector_id + mes`	Sector-mes	Ago–dic 2025
`complementarios/metas_2025_ancho.csv`	Dimensión	30	`sector_id + indicador`	Meses en columnas	Ene–dic; hacer *melt*

- **Filas físicas vs. entidades vs. exposición:** 253.404 filas de telemetría (incluyen repeticiones), 30 sectores válidos y 262.800 sector-horas esperadas (130.320 + 22.320 + 110.160). La grilla define la exposición para la cobertura; ago–dic recibió 100.000 filas para 110.160 sector-horas (10.160 nunca llegaron).
- **Hash y procedencia:** los ocho archivos se verifican con SHA-256 contra `metadatos.json`. Paquete v2, UTF-8, UTC, semillas 20260924 y 20261004, fecha de paquete 2026-10-01. Datos 100% sintéticos; el nombre de la empresa es contexto docente.

3. Calidad y pertinencia

Se evaluaron 27 reglas por lote (`matriz_reglas.csv`) y un perfil por lote, sector, mes y modo (`perfil_calidad.csv`). Cada problema se clasifica como:

- **Defecto:** incumple el contrato del dato. Se dividen en:
  - *recuperables*, porque el formato está documentado: coma decimal (600), fecha dd/mm (500), modo con espacios (1.567);
  - *no recuperables*: 764 copias exactas, 353 fechas imposibles, 609 filas de sector inexistente, 250 volúmenes `PENDIENTE`, 250 unidades desconocidas, 1.012 entradas negativas, 350 salidas > entrada, 350 interrupciones de 90 min y 3.732 volúmenes vacíos.
- **Extremo plausible**, que se marca y no se borra: 4.506 presiones y 146 energías fuera de 1,5 RIC de su sector, en su mayoría presiones bajas.
- **Ausencia estructural**, que no es defecto: no hay tarifas en ene–jul (153.251 filas) y `metas_ancho` no trae ago–dic.

Métricas de calidad (ene–dic, con denominador propio):

Métrica	Valor
Cobertura de lecturas válidas	251.682 de 262.800 sector-horas (95,8%)
Copias exactas	764 de 253.404 filas (0,30%)
Unidad desconocida	250 de 253.404 (0,10%)
Salida > entrada	350 de 248.160 (0,14%)
Interrupción fuera de 0–60 min	350 de 253.404 (0,14%)
Atraso de carga > 2 h	34.016 de 253.051 (13,4%)

Sesgo de faltantes: las horas sin lectura se concentran en A-S26 a A-S29, con 76% de cobertura (11.183 de 14.688 sector-horas). Por eso su continuidad solo se acota entre ≈ 72,5% (si las horas faltantes tuvieron 60 min de corte) y ≈ 97,6% (si tuvieron 0). Un promedio sobre lo disponible ocultaría esas horas.

KPI más sensibles a un mal tratamiento (ene–dic):

- Sumar litros como m³ hunde la intensidad energética en un 99,4% (0,265 → 0,0015 kWh/m³).
- Incluir entradas negativas y salida > entrada baja la diferencia de volúmenes de 16,1% a 15,3%.
- La continuidad cambia en décimas de punto si se usan los minutos > 60 (−0,21) o si las horas ausentes se cuentan como 0 min (+0,07). Esa diferencia importa frente a una meta de 99,5%.

Pertinencia: la fuente sirve para **comparar sectores entre sí** y priorizar. No sirve para afirmar el cumplimiento exacto de la meta en sectores con baja cobertura, ni para atribuir causas.

4. Hallazgos

H1: El grupo A-S20 a A-S29 concentra la diferencia de volúmenes y los datos faltantes

- **Observación:**
  - En ago–dic, A-S20 a A-S29 pierden el 24,0% del volumen de entrada (29.002 lecturas con volumen válido), contra 15,0% del resto (67.048 lecturas), tanto en m³ como en L. El grupo saltó de 13% a 21% en abril y a 24% en agosto.
  - Ese mismo grupo tiene los 2.200 de 2.200 volúmenes vacíos de ago–dic (6,95% de sus 31.645 lecturas).
  - A-S26 a A-S29 reúnen 3.505 de las 10.660 sector-horas sin lectura válida, con 76,1% de cobertura (11.183 de 14.688).
- **Hipótesis:** un cambio de medición en la entrada o la salida, o una pérdida real. Estos datos no permiten separar ambas explicaciones.
- **Decisión:** priorizar inspecciones en este grupo, empezando por los medidores (D-02).
- *Figuras: `T4_d_segmentos.png`, `T2_nulos_por_sector.png`, `T3_cobertura_interrupciones.png` · ago–dic 2025 · % de m³ y % de lecturas · 30 sectores. Limitación: el grupo se identificó en los datos; no se atribuye fuga ni falla de sensor.*

H2: La meta de continuidad no distingue sectores: los 30 quedan bajo 99,5%

- **Observación:**
  - Incluso suponiendo 0 minutos de corte en las horas desconocidas, la continuidad ponderada por conexiones va de 96,49% a 98,97% en ago–dic: 30 de 30 sectores bajo la meta.
  - Las horas en mantenimiento tienen interrupción en 6.206 de 6.206 casos, contra 4.596 de 245.126 en operación normal (1,9%).
- **Hipótesis:** el modo de mantenimiento registra cortes planificados.
- **Decisión:** priorizar por posición relativa (percentiles) y no por cumplimiento de la meta; separar mantenimiento de operación normal en el KPI de interrupciones.

- *Figura: `T3_continuidad_limites.png` · ago–dic 2025 · % de minutos-conexión · 30 sectores. Limitación: los límites 0/60 son escenarios extremos, no probabilidades; la meta es docente.*

H3: Ago–dic, el período del ranking, es el lote menos confiable

- **Observación:**
  - 21.379 de 99.800 lecturas (21,4%) llegan con más de 2 h de atraso, contra 10.801 de 130.841 (8,3%) en ene–jun. Ago–dic es peor también con umbrales de 1, 3 y 6 h.
  - Ago–dic trae 7 tipos de defecto que no existían en ene–jul.
  - Le faltan 10.660 de 110.160 sector-horas válidas (9,7%), contra 0,3% en ene–jul.
- **Hipótesis:** otro proceso de captura o de transmisión en ago–dic. No es verificable con estos datos.
- **Decisión:** reportar cada KPI de ago–dic junto a su cobertura. En un tablero, advertir que las horas recientes pueden estar incompletas.
- *Figuras: `T2_atraso_carga.png`, `T2_reglas_por_lote.png` · ene–dic 2025 por lote · % de filas · 253.051 lecturas con ambas fechas válidas. Limitación: el % exacto depende de interpretar `"latency": 2` como horas (D-01); la comparación entre lotes no depende de ello.*

H4: El costo por m³ sube 15,8% por la tarifa, y no convertir unidades lo distorsiona todo

- **Observación:**
  - El costo de energía por m³ sube de 34,89 a 40,40 CLP entre agosto y diciembre. El 96% del alza (5,28 de 5,51 CLP/m³) se explica por la tarifa y no por la energía por m³.
  - La razón de sumas da 37,61 CLP/m³ y el promedio de razones horarias, 38,28.
  - Sin convertir litros, el costo daría 0,15 CLP/m³.
- **Hipótesis:** el alza refleja el cambio de tarifa del escenario, no un cambio de la operación.
- **Decisión:**
  - usar la razón de sumas como KPI;
  - separar los efectos de energía y de tarifa;
  - convertir L → m³ antes de sumar y excluir la unidad desconocida.
- *Figuras: `T4_costo_m3.png`, `T2_sesgo_kpi.png` · ago–dic 2025 · CLP/m³ · 96.050 lecturas con volumen válido y tarifa. Limitación: no hay tarifas antes de agosto y su ausencia no es 0.*

5. Propuesta de inspección

Método:

- **Puntaje:** promedio de los percentiles de continuidad observada, diferencia de volúmenes y energía (kWh/m³ y CLP/m³, promediados como un solo criterio).
- **Tipo de inspección:** la confiabilidad del dato decide si se revisa el **sensor primero** (más de 2 × la mediana de filas con defecto, ≈ 4,6%) o la **operación** (D-02).
- **Filtro de cobertura: 80%**. Excluye solo a A-S26 a A-S29 (≈ 76%), cuya continuidad es demasiado incierta para compararla. Con filtros de 80, 85 y 90% el resultado es idéntico, y ningún sector llega a 95% (el máximo es 93,3%).

#	Sector	Por qué (percentiles, 1 = peor)	¿Cambia con el filtro?	Inspección y evidencia a recolectar
1	**A-S20**	Continuidad 0,96 (96,3% observada); diferencia 0,96 (24,0%); energía 0,69. Cobertura 92,0%	No	**Sensor primero:** 316 de 3.386 lecturas con defecto (9,3%). Contrastar los medidores de entrada y salida y la transmisión de volumen; después, la operación
2	**A-S25**	Continuidad 0,85 (96,9%); diferencia 0,88 (24,0%); energía 0,85 (0,304 kWh/m³). Cobertura 92,8%	No	**Sensor primero:** 311 de 3.416 lecturas con defecto (9,1%). Mismo contraste de medidores y revisión de la presión
3	**A-S10**	Energía 0,92: 0,324 kWh/m³ y 43,7 CLP/m³, contra medianas de 0,263 y 38,6. Continuidad 0,69; diferencia 0,77 (15,1%)	No	**Operación:** 80 de 3.424 lecturas con defecto (2,3%). Revisar bombeo, horario de las bombas y presión

Sin filtro, A-S27 quedaba 5.º. A-S26 a A-S29 requieren primero recuperar su transmisión de datos, para poder evaluarlos.
Advertencia: los percentiles amplifican diferencias pequeñas entre los sectores cercanos a 15% de diferencia de volúmenes (14,9–15,1%). La elección de A-S10 descansa sobre todo en su energía, que es claramente mayor.

6. Límites de interpretación

1. Los datos y metas son sintéticos; no permiten inferir potabilidad, cumplimiento regulatorio ni resultados reales de la empresa.
2. Los faltantes generan límites de continuidad y pueden cambiar el ranking; un promedio sobre lecturas disponibles no representa necesariamente el sector completo.

3. Una asociación entre presión, energía, interrupciones o diferencia de volúmenes no demuestra causalidad; el modelo omite almacenamiento y transferencias.
4. Dos umbrales son decisiones del grupo y no vienen dados por la fuente: el atraso > 2 h (D-01) y la presión baja < 3,0 bar (D-08). Sus resultados se informan con sensibilidad.

7. Plan de limpieza para la E2

Cada paso queda en la bitácora, y los originales no se modifican.

Acción	Casos
Recuperar con regla documentada	Coma decimal → punto; fecha dd/mm → UTC; `modo_operacion` con strip y minúsculas; L → m³ (43.020 filas)
Deduplicar	764 copias exactas, conservando una por `medicion_id`
Excluir sin imputar de los KPI afectados	Fechas imposibles, sector inexistente, `PENDIENTE`, unidad desconocida (no se adivina), entrada negativa, salida > entrada, volúmenes vacíos
Tratar como desconocido	Interrupciones > 60 min: la hora entra a los límites 0/60, no se recorta a 60
Marcar sin borrar	Extremos de presión y energía; lecturas atrasadas y cargas anteriores a la hora medida
Respetar ausencias estructurales	Tarifas solo ago–dic; usar `metas_2025_ancho` con *melt* (sin concatenar versiones); horas ausentes visibles en la grilla

8. KPI y métricas de calidad

Las 12 fichas están en `fichas_indicadores.csv`, con fórmula, numerador, denominador, población, tratamiento de nulos, umbral y acción. Valores de ago–dic:

KPI	Fórmula	Valor
KPI-01 Continuidad ponderada	1 − min. interrumpidos / min. de conexión (límites 0/60)	30 de 30 sectores bajo 99,5%
KPI-02 Diferencia de volúmenes	Σ(entrada − salida) / Σ entrada	18,2% (96.050 lecturas)
KPI-03 Intensidad energética	Σ kWh / Σ m³ de entrada	0,264 kWh/m³
KPI-04 Costo de energía	Σ(kWh × tarifa) / Σ m³	37,61 CLP/m³
KPI-05 Horas con interrupción	horas con min > 0 / horas válidas	5,0% (de 99.150)
KPI-06 Horas con presión baja	horas < 3,0 bar / lecturas válidas	2,2% (de 99.500)

Las 6 métricas de calidad (KRI-01 a KRI-06) están en la sección 3.

9. Declaración de uso de IA

Se usaron:

- **Claude Code**, en T2, T5 y la estructura;
- **Codex**, en T1 y T3;
- **OpenCode con Claude Haiku**, en T4.

En todos los casos se verificó:

- ejecutando cada notebook desde un kernel nuevo, sin errores;
- contrastando las cifras entre tareas (por ejemplo, 99.500 lecturas válidas de ago–dic en T2, T3 y T4);
- comprobando los hashes de los datos originales;
- revisando las figuras a mano.

Una revisión cruzada corrigió errores de la IA, como una ficha con un tipo mal escrito y un notebook con un error guardado. El detalle por integrante está en `uso_ia.md`.